

1

1.1

$$\text{Var}(Y) = E[Y^2] - E^2[Y] = E[(W^T X)^2] - E^2[W^T X] =$$

$$E[(W^T X)(X^T W)] - W^T E[X X^T] W - W^T 0 =$$

$$W^T C W$$

1.2

$$L(w, C, \mu) = w^T (w - \mu (\|w\|^2 - 1))$$

נכנסים למינימום של הפונקציה

לשם כך נגזרת

$$w^T C w = \sum_{i=1}^n \sum_{j=1}^n C_{ij} w_i w_j =$$

$$w_1 \sum_{j=1}^n C_{1j} w_j + w_2 \sum_{j=1}^n C_{2j} w_j + \dots + w_n \sum_{j=1}^n C_{nj} w_j =$$

לפיכך נגזרת הפונקציה לפי  $w_1$  נקבל:

$$= C_{11} w_1 + w_1 \sum_{j=2}^n C_{1j} w_j + w_2 C_{21} w_1 + w_2 \sum_{j=2}^n C_{2j} w_j + \dots + w_n C_{n1} w_1 + w_n \sum_{j=2}^n C_{nj} w_j$$

(הנגזרת לפי  $w_1$  היא)

$$\nabla_{w_1} f = 2C_{11} w_1 + \sum_{j=2}^n C_{1j} w_j + C_{21} w_2 + C_{31} w_3 + \dots + C_{n1} w_n =$$

$$2C_{11} w_1 + \sum_{j=2}^n C_{1j} w_j + \sum_{j=2}^n C_{j1} w_j = 2C_{11} w_1 + \sum_{j=1}^n (C_{1j} w_j + C_{j1} w_j) =$$

$$2C_{11} w_1 + \sum_{j=1}^n (C_{1j} + C_{j1}) w_j \stackrel{\text{סימטריה}}{=} 2C_{11} w_1 + 2 \sum_{j=1}^n C_{1j} w_j =$$

$$= 2 \left( \sum_{j=1}^n C_{1j} w_j \right) = 2(Cw)_1$$

אכן שלא התבאר רק

שהוא הוא הקורנטיב בקומו

$$\nabla_{w_i} f = 2(Cw)_i$$

המשוואה  $w$  ניתן להכתיב

ובכך נקבל:

$$\nabla_w f = 2Cw$$

כעת נשאר רק להציב את  $\mu$ :

$$\mu (\|w\|^2 - 1) = \mu \left( \sum_{i=1}^n w_i^2 - 1 \right) \Rightarrow \nabla_{w_i} g = 2w_i \cdot \mu \Rightarrow \nabla_w g = 2\mu w$$

ובתוספת נגזרת קיצון:

$$2Cw - 2\mu w = 0 \quad \text{s.t.} \quad \|w\|^2 = 1 \Leftrightarrow Cw = \mu w$$



כאלה, בלעדיהם נשאלת השאלה: מה הוא? מהו זה?  
ואם אכן אלו הם, הרי הם נשאלים: מהו זה?

1.3.1

$$X_1 \sim N(0, 1), X_2 \sim N(0, 4), X_1 \perp X_2$$

امیر:

למשי'צת הקולצ'יה היא למדינת יק e:

$$(X^T X)_{ij} = C_{ij} = \begin{cases} \text{Var}(x_i) & i=j \\ \text{cov}(x_i, x_j) & i \neq j \end{cases}$$

1891

$$C = \begin{bmatrix} 1 & 0 \\ 0 & 4 \end{bmatrix}$$

1.3.2

3: ו' ע' ג' ח' ב' י' ז' ט' י"ב

להם פולחן האלילים

$$p(\lambda) = |C - \lambda I| =$$

$$= \begin{vmatrix} 1-\lambda & 0 \\ 0 & 4-\lambda \end{vmatrix} = (1-\lambda)(4-\lambda) =$$

$$\Rightarrow \lambda_1 = 1, \lambda_2 = 4$$

רמב"ם דף כ"א

$$\left[ \begin{array}{cc|c} 1 & -4 & 0 \\ 0 & 4 & 0 \end{array} \right] \Leftrightarrow \left[ \begin{array}{cc|c} -3 & 0 & 0 \\ 0 & 0 & 0 \end{array} \right] \Leftrightarrow$$

$$-3W_1 = 0 \quad \Leftrightarrow W_1 = 0$$

$\|u\|^2 = 1$  אם  $u$  נורמלית

$$w = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

$\hookrightarrow \omega_2 = 1 \rightarrow 15 \rightarrow 10 \rightarrow 11$


### ! 3.3 Appendix

(1.4)  $\text{var}(Y) = \text{var}(wX) = w^2 \text{var}(X) = w^2 E(X^2) =$

נניח שיש לנו 5 ימים בן שבתות ויום חול אחד. כל יום חול יבוא אחרי שבת.

## Appendix

### Answer for question 1.3.3



בציור ניתן לראות נקודות שהוגרלו כאשר לממד הראשון שונות קטנה יותר מלממד השני, הוקטור שהתקבל מצביע על הכיוון בו השונות בדוגמאות היא גדולה.

### Answer for question 1.5

בכיתה הגדרנו את בעיית PCA בעזרת פונקציית אנרגיה, ודרשנו למזער את ערכה כפונקציה של הוקטורים  $u$  (וקטור הורדת הממד) ו- $v$  (וקטור השחזור). ראינו כי מזעור של הפונקציה מתקבל בעזרת לקיחת  $u$  ו- $v$  שווים זה לזה, וכן ע"י בחירתם להיות הוקטור העצמי המתאים לערך העצמי הגבוה ביותר של מטריצת הקורלציה של הקלט. אמנם, ראינו בכיתה כי עשויים להיות כמה וקטורים אופטימליים עבור מזעור פונקציית האנרגיה, אך בשל כך בחרנו אותם להיות שייכים לקבוצת הוקטורים שהנורמה שלהם היא 1.

זהו בדיוק התהליך אותו הראינו בסעיף ב' בשאלה זו: מצאנו כי שונות הפלט הגדולה ביותר תתקבל על ידי בחירת הוקטור העצמי המתאים לערך העצמי הגבוה ביותר של מטריצת הקורלציה של הדוגמאות. במקרה של סעיף ב' הערך  $\gamma$  שאת שונותו אנחנו מנסים למקסם, מייצג את הדוגמאות לאחר הקטנת הממד, ומקסום שונותו שקול למזעורה של פונקציית האנרגיה (המודדת כמה 'מייצגת' היתה הורדת הממד).

# ex5\_computation\_and\_cognition

December 12, 2019

```
[0]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
```

## 0.0.1 Q1

```
[0]: def sample_2d(p,f,sig_x):
    x1 = np.random.uniform(-1,1)
    determinator = np.random.choice([True,False], p=(p,1-p))
    if determinator:
        eps = np.random.normal(0,sig_x)
        x2 = np.sin(f*x1) + eps
    else:
        x2 = np.random.uniform(-1,1)
    return pd.Series([x1, x2])
```


## 0.0.2 Q2

```
[0]: p=0.95
f=4
sig_x=0.1
K=100
eta=1
sig=1

# setup
experiment = pd.DataFrame(np.column_stack((np.repeat(p,20000),np.
→repeat(f,20000),np.repeat(sig_x,20000))),
    columns=["p", "f", "sig_x"])

# sampling according to the parameters
experiment[["x1", "x2"]] = experiment.apply(lambda row:
→sample_2d(row["p"],row["f"],row["sig_x"]), axis=1)
repres_mat = np.random.uniform(-1,1,size=(2,K))
```

```
[110]: experiment[["x1","x2"]].plot(kind="scatter", x="x1", y="x2", s=0.1, alpha=0.5,
      ↳figsize=(15,8))
plt.scatter(x=repres_mat[0],y=repres_mat[1], c="r", label="representative_
      ↳point")
plt.legend(loc="lower left")
plt.plot(repres_mat[0],repres_mat[1], c="y", linestyle="--")
plt.xlabel("x1",fontsize=15)
plt.ylabel("x2",fontsize=15)
plt.title("Random 100 Representatives for 2D 20000 Data Points connected_
      ↳according to their idx order\n", fontsize=15)
plt.text(x=-1.1,y=1.5,s="*These representatives will be the initialization for_
      ↳the SOM algorithm")
plt.show()
```



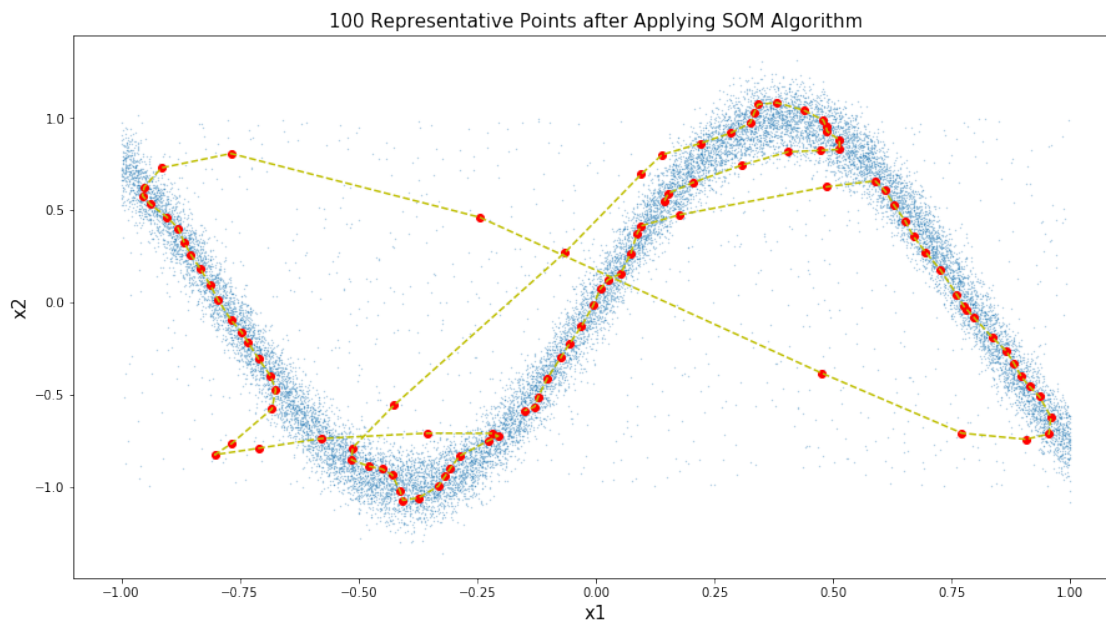
### 0.03 Q3

```
[0]: for example in experiment[["x1","x2"]].values:
      exam_rep_diff = np.repeat(example,K).reshape(2,K) - repres_mat
      dists = np.apply_along_axis(np.linalg.norm,0, exam_rep_diff)
      l = np.argmin(dists)
      arg_for_pi = np.arange(repres_mat.shape[1]) - np.repeat(l,repeats=repres_mat.
      ↳shape[1]) # 0 < arg+l < K-1
      pis = np.exp(-(arg_for_pi)**2/(2*(sig**2)))
      pis /= np.sum(pis)
      repres_mat += eta*exam_rep_diff*pis
```



#### 0.0.4 Q4

```
[112]: experiment[["x1","x2"]].plot(kind="scatter", x="x1", y="x2", s=0.1, alpha=0.5,
    figsize=(15,8))
plt.scatter(x=repres_mat[0],y=repres_mat[1], c="r", label="representative_
    point")
plt.plot(repres_mat[0],repres_mat[1], c="y", linestyle="--")
plt.title("100 Representative Points after Applying SOM Algorithm", fontsize=15)
plt.xlabel("x1",fontsize=15)
plt.ylabel("x2",fontsize=15)
plt.show()
```



#### 0.0.5 Q5

##### Seif a

SOM algo updates representative with close indecis in a similar way, as the pi function of the updating rule forces it. Therefore the yellow line is quite going from one representative to the next one (there is noise so there are few points that violate this). Basically, the distances between representative points are similar in the most of the time. This is because SOM force the K's points to represent the data, and the data is close to be uniform in the two dimensions. The data is simply uniform in the first dimension, and in the second it is spread most of the time on the sinus curve (with a small noise). The places in the data which violated the uniformity, produce representatives that violated the equal distances.

##### Seif b

The magnitude of noise in the encoding doesn't affect the organization one after another of the representative, because the rule of close-idx-of-representatives update together doesn't change

neither. However, the noise do affect the ability of the algo to assign representatives which will represent the data in a satisfy way, and therefore as the noise will increase the representatives will represent the examples in a bad way.